

# **Doppio Motore ML per il Trading Algoritmico: Previsione e Gestione Dinamica del Rischio su MT4**

1. Introduzione
2. Architettura dei modelli di Machine Learning
  - 2.1. Random Forest - Previsione trade
  - 2.2. AMM - Adaptive Money Management
3. Integrazione dei modelli in ambiente MT4
4. Metodologia di test e parametri comuni
5. Risultati - Confronto per asset
  - 5.1. XAU/USD
  - 5.2. NAS100
  - 5.3. DJ30
  - 5.4. S&P500
  - 5.5. DAX40
  - 5.6. USOIL
  - 5.7. BTC/USD
  - 5.8. EUR/USD
  - 5.9. USDJPY
  - 5.10. AUDUSD
6. Analisi comparativa con/senza ML
7. Conclusioni e sviluppi futuri

# 1. Introduzione

Nel presente lavoro ho voluto esplorare l'integrazione di due modelli di Machine Learning all'interno di un sistema automatico di trading (Expert Advisor - EA), con l'obiettivo di testare l'efficacia su più strumenti finanziari, in particolare XAU/USD, indici, commodity e coppie Forex.

I modelli sono stati implementati in linguaggio C++ e successivamente integrati in ambiente MT4 tramite una DLL. Gli algoritmi utilizzati comprendono:

- **Random Forest** per l'analisi predittiva dell'esito di un trade (output 1 o -1).
- **Regressione Lineare** combinata con un sistema di pesi adattivi per calcolare un moltiplicatore di rischio dinamico (range 0.5 – 1.5).

La strategia operativa, volutamente mantenuta riservata nei dettagli, si basa su conferme volumetriche e logiche di trend-following. L'EA è stato testato su più asset con timeframe H1, con posizionamento dinamico di Take Profit e Stop Loss basato sulla volatilità.

Per quanto riguarda il mercato Forex, è stata impiegata una versione tecnica della strategia, escludendo l'analisi volumetrica, data la scarsa affidabilità dei volumi nei cross valutari. In questo contesto, l'ingresso è stato definito da condizioni di trend following e 2 conferme tecniche.

Ho utilizzato lotti differenti in base agli asset, 0.5 lotti per gli asset che utilizzo abitualmente con questa strategia. Invece per quelle che non utilizzo, ma su cui ho semplicemente fatto i test, ho utilizzato 0.05 lotti.

I risultati riportati, sono relativi all'utilizzo dei modelli con il dataset fornito insieme ad essi. In questo modo chi utilizza i modelli può capire su che asset hanno performato meglio.

## 2. Architetture dei modelli di Machine Learning

### 2.1 Random Forest - Previsione trade

Il modello è stato progettato per **prevedere la probabilità di successo** di un'operazione di trading sulla base di 7 variabili di input che descrivono lo stato del mercato in un dato momento. L'output è una probabilità compresa tra 0 e 1, che indica quanto è probabile che l'operazione sia vincente.

## Feature utilizzate

Il modello prende in input un vettore di caratteristiche (**TradeData**) che contiene:

- **ema**: valore corrente della media mobile esponenziale (EMA)
- **adx**: valore della Average Directional Index
- **poc**: Point of Control (livello di prezzo più scambiato)
- **vah**: Value Area High
- **val**: Value Area Low
- **volume**: volume attuale del mercato
- **atr**: Average True Range (indicatore di volatilità)

## Struttura interna: Random Forest semplice

Il modello è una Random Forest semplificata costituita da più alberi binari (**TreeNode**). Ogni albero effettua una singola divisione (split) su una delle feature casuali del dataset.

### Ogni albero contiene:

- **feature**: l'indice della feature da utilizzare per lo split.
- **threshold**: la soglia su cui dividere i dati (inferiore o superiore).
- **left, right**: nodi foglia, ognuno dei quali contiene una probabilità calcolata sui dati di training. Se il valore è minore della soglia, si va a sinistra, altrimenti si va a destra.

Ogni albero valuta in quale “ramo” cade il dato di input e restituisce una probabilità di successo basata sui dati presenti in quel ramo.

## Funzionamento:

Addestramento (**train**):

Il metodo **train** prende in input un dataset di **TradeData** da un file CSV.

Per ogni albero (**num\_trees**), seleziona casualmente una feature e una soglia.

Costruisce due rami:

- **left**: contiene i dati con  $feature < threshold$
- **right**: contiene i dati con  $feature \geq threshold$

Calcola la **probabilità di successo** per ogni ramo (quanti trade vincenti su totale).

I modelli vengono salvati in un file binario (**random\_forest\_model.bin**).

Previsione (**predict**):

Carica il modello se non è già in memoria.

Per ogni albero:

- Controlla se il valore della feature è sopra o sotto la soglia.
- Recupera la probabilità di successo associata.

Calcola la **media delle probabilità** restituite da tutti gli alberi.

L'output è un valore tra 0.0 e 1.0, interpretabile come **confidenza**.

### Considerazioni:

Questa Random Forest è volutamente leggera e ottimizzata per uso embedded su piattaforme come MT4, dove le risorse sono limitate. Non implementa pruning, bagging o splitting multipli, ma è costruita per velocità e integrazione real-time.

## 2.2. AMM - Adaptive Money Management

L'obiettivo di questo modello è quello di calcolare dinamicamente un moltiplicatore di rischio (compreso tra 0.5 e 3.0) in base alle condizioni del mercato, da applicare alla size di ogni operazione. Questo consente una gestione adattiva del rischio, aumentando l'esposizione nei momenti più favorevoli e riducendola in presenza di incertezza o debolezza del trend.

### Struttura del modello ibrido: Random Forest + Regressione Lineare

Il modello AMM è composto da due sottosistemi principali:

#### 1. Random Forest (Classificatore)

- Utilizza una foresta di 10 alberi decisionali (**DecisionTree**) estremamente leggeri.
- Ogni albero seleziona casualmente una **feature** e una soglia, e vota per una direzione del rischio: **+1** (rischio elevato) o **-1** (rischio ridotto).
- L'output della Random Forest è la **maggioranza dei voti**, restituendo un valore discreto: 1 o -1.

#### 2. Linear Regression (Regressore)

- Il modello applica una **regressione lineare semplificata** per fornire un output continuo (non classificato).
- I pesi iniziali sono tutti settati a 0.5 (non viene effettuato un vero training supervisionato sul dataset).
- Il valore predetto è la **somma pesata delle feature**, utilizzata come valore indicativo del rischio atteso.

### Combinazione dei due modelli

L'output finale del moltiplicatore viene calcolato come:

$\text{risk\_multiplier} = (0.7 * \text{output\_random\_forest}) + (0.3 * \text{output\_regressione});$

Dove:

- `output_random_forest`  $\in \{-1, 1\}$
- `output_regressione`  $\in \mathbb{R}$  (valore continuo)

Questo permette al sistema di **fondere la logica binaria della Random Forest** (basata su classificazione) con la **fluidità della regressione lineare**, producendo un risultato più robusto e adattivo.

## Filtri aggiuntivi

### Filtro Trend (ADX)

- Se `ADX > 25`, il trend è considerato forte → rischio aumentato del 20%.
- Se `ADX < 15`, il trend è considerato debole → rischio ridotto del 20%.

### Filtro Storico (Media Mobile)

- Il valore del moltiplicatore viene **smussato con una media mobile degli ultimi 5 valori**.
- Questo introduce stabilità e previene oscillazioni improvvise.

### Normalizzazione

- Il moltiplicatore viene forzato nel range **[0.5, 3.0]**, garantendo coerenza con i vincoli della strategia.

Il modello è pensato per essere **lightweight**, perfetto per integrazione in ambienti come MetaTrader 4 (MT4). Tutta la logica è contenuta in una DLL esterna e richiamata direttamente dall'EA in tempo reale. L'utilizzo combinato di classificazione e regressione consente un controllo **più fine e intelligente** del rischio, rispetto a sistemi puramente discreti.

## 3. Integrazione dei modelli in ambiente MT4

Per la completa integrazione ed utilizzo dei modelli in mt4 visionare lo pseudo codice.

## 4. Metodologia di test e parametri comuni

Al fine di valutare l'efficacia reale dei modelli di Machine Learning integrati all'interno dell'Expert Advisor (EA), è stato condotto un test sistematico e simulato su diversi asset finanziari, tra cui commodity (XAU/USD, USOIL, BTC/USD), indici

(NAS100, DJ30, S&P500, DAX40) e coppie Forex (EUR/USD, USD/JPY, AUD/USD).

L'obiettivo principale del test non era semplicemente massimizzare la performance, ma analizzare la robustezza, la consistenza dei risultati nel tempo e la capacità dei modelli ML di adattarsi a condizioni di mercato differenti, inclusi periodi di elevata direzionalità, lateralizzazione e incertezza.

Tutte le simulazioni sono state condotte con condizioni realistiche, includendo:

- Spread e slippage variabili, positivi e negativi, simulati su base asset-specifica.
- Commissioni fisse di 7€ per ogni operazione.
- Logica di trailing stop e gestione dinamica di TP/SL basata sulla volatilità (ATR).
- Test annuale completo, considerando l'effetto dei cicli stagionali (aprile, agosto e dicembre come mesi statisticamente meno performanti).

Parametri standard utilizzati in ogni test:

- Timeframe operativo: H1
- Capitale iniziale: 100.000 €
- Lotto fisso (versione base): 0.5
- Lotto fisso (versione conservativa): 0.05
- Moltiplicatore dinamico (con modello AMM): da 0.5x a 1.5x del lotto
- Modelli ML impiegati: Random Forest per la previsione del trade, Linear Regression per la gestione del rischio (AMM)
- Indicatori tecnici: EMA, ADX, POC, VAH, VAL, Volume, ATR, ADL
- Condizione di ingresso generale: trend-following con conferma tecnica o volumetrica
- Strategia Forex: adattata per operare senza conferme volumetriche, utilizzando rimbalzi tecnici su Order Block + EMA50 con tolleranza di 5 pips

Ogni test ha generato output grafici comprensivi di:

- Andamento del capitale (equity line)
- Istogramma dei profitti mensili
- Win rate
- Drawdown massimo
- Profitto assoluto e percentuale

La metodologia è stata mantenuta coerente su tutti gli asset testati, garantendo una base di confronto equa tra la versione con ML e quella senza ML. Questo approccio permette di valutare in modo trasparente il contributo effettivo dell'intelligenza artificiale all'interno del sistema di trading automatico.

## 5. Risultati - Confronto per asset

### 5.1. XAU/USD (0.5 lotti)

Nel test effettuato su XAU/USD, uno degli asset più complessi da gestire a causa della sua volatilità e sensibilità agli eventi macroeconomici, si è osservato un risultato particolarmente interessante: **la versione con Machine Learning non ha prodotto un aumento sostanziale dei profitti totali rispetto alla versione base**, ma ha evidenziato una **notevole differenza nella qualità del rendimento**.



#### Consistenza e regolarità

L'equity line della strategia con ML mostra un andamento molto più **progressivo, stabile e controllato**. Il capitale cresce con minori fasi di drawdown e presenta una distribuzione dei profitti **più costante mese per mese**, anche durante i mesi solitamente più instabili (come aprile, agosto e dicembre).

Questo riflette la capacità del modello AMM di **adattare dinamicamente l'esposizione al rischio**, e della Random Forest di **filtrare i trade meno promettenti**.

#### Equity Curve e Profitti mensili



Strategia con Machine Learning



Win Rate	70.43%
Max Drawdown	1.97%
Profitto Assoluto	33.390\$
Profitto Percentuale	33.4%



## Strategia senza Machine Learning



Win Rate	67.52%
Max Drawdown	3.59%
Profitto Assoluto	30.630\$
Profitto Percentuale	30.6%

## Conclusione su XAU/USD

La strategia con ML, pur mantenendo un livello di profitto simile alla versione base, ha notevolmente migliorato la stabilità del portafoglio, evidenziando meno sbalzi, drawdown contenuti e una crescita più armonica del capitale. Questo rappresenta un chiaro valore aggiunto in termini di gestione del rischio e

qualità del rendimento, soprattutto per un asset come l'oro.

## 5.2 – NAS100 (0.05 lotti)


Nel caso del NAS100, noto per l'elevata volatilità e la forte esposizione al tech americano, la strategia ha mostrato un comportamento quasi inverso rispetto a quello osservato su XAU/USD.

### Osservazioni chiave

- La **versione con ML** ha prodotto un risultato complessivamente positivo, ma ha mostrato una **crescita meno lineare e più irregolare**. Alcuni mesi (come aprile e dicembre) hanno inciso negativamente sul bilancio annuale, suggerendo che i modelli non abbiano sempre filtrato correttamente le condizioni sfavorevoli.
- La **versione senza ML**, al contrario, ha evidenziato una **crescita più fluida e costante**, con equity line più armonica e una distribuzione mensile dei profitti generalmente più solida e coerente.



Questo risultato sottolinea come, su un asset molto direzionale come NAS100, **un approccio tecnico senza modulazione dinamica del rischio possa in alcuni casi risultare più efficace** rispetto a un modello adattivo.

Strategia con Machine Learning



Win Rate	68.31%
Max Drawdown	0.46%
Profitto Assoluto	4.467\$
Profitto Percentuale	4.47%

## Strategia senza Machine Learning



Win Rate	73.27%
Max Drawdown	0.33%
Profitto Assoluto	6.670\$
Profitto Percentuale	6.67%

## Conclusione su NAS100

In questo contesto, la versione senza ML ha performato meglio sia in termini di stabilità che di coerenza operativa, mentre l'integrazione del modello di Machine Learning ha introdotto una variabilità non sempre controllata, probabilmente a causa della natura altamente ciclica e rumorosa del NASDAQ nel periodo testato.

### 5.3 – DJ30 (Dow Jones) (0.05 lotti)


Sul Dow Jones (DJ30), un indice storicamente più stabile rispetto a NASDAQ ma comunque soggetto a fasi di accelerazione e rallentamento ciclico, il confronto tra le due versioni della strategia ha offerto risultati molto chiari.


#### Osservazioni chiave

- La **strategia con Machine Learning** ha mostrato una **crescita costante e progressiva**, con un buon controllo del rischio e drawdown molto contenuti, specialmente nella seconda metà dell'anno.
- Tuttavia, **alcuni mesi (agosto, ottobre, novembre)** hanno mostrato leggeri ritorni negativi, sintomo di una modulazione prudente ma non sempre ottimale nelle fasi di congestione.
- La **versione senza ML** è partita con un forte drawdown nei primi mesi (in particolare gennaio e aprile), ma ha poi recuperato con decisione, mostrando un'accelerazione evidente da giugno in poi.

Questo suggerisce che, su un indice più “prevedibile” come il DJ30, la gestione dinamica del rischio portata dal modello AMM **può migliorare la stabilità** ma, se troppo conservativa, **può limitare la performance in fasi fortemente bullish**.


#### Strategia con Machine Learning






Win Rate	70.53%
Max Drawdown	0.51%
Profitto Assoluto	4.955\$
Profitto Percentuale	4.95%

## Strategia senza Machine Learning





Win Rate	60%
Max Drawdown	0.83%
Profitto Assoluto	2.554\$
Profitto Percentuale	2.55%

## Conclusione su DJ30

La versione con ML ha garantito una gestione del capitale molto regolare, riducendo significativamente i drawdown e offrendo una curva equity più “pulita”. D’altra parte, la versione senza ML ha recuperato più tardi, ma ha saputo sfruttare meglio la fase bullish del secondo semestre.

Questo conferma che l’uso del ML è particolarmente utile per stabilizzare, ma che un eccesso di prudenza può limitare il potenziale in ambienti fortemente rialzisti come quello vissuto nel 2023 sul Dow Jones.

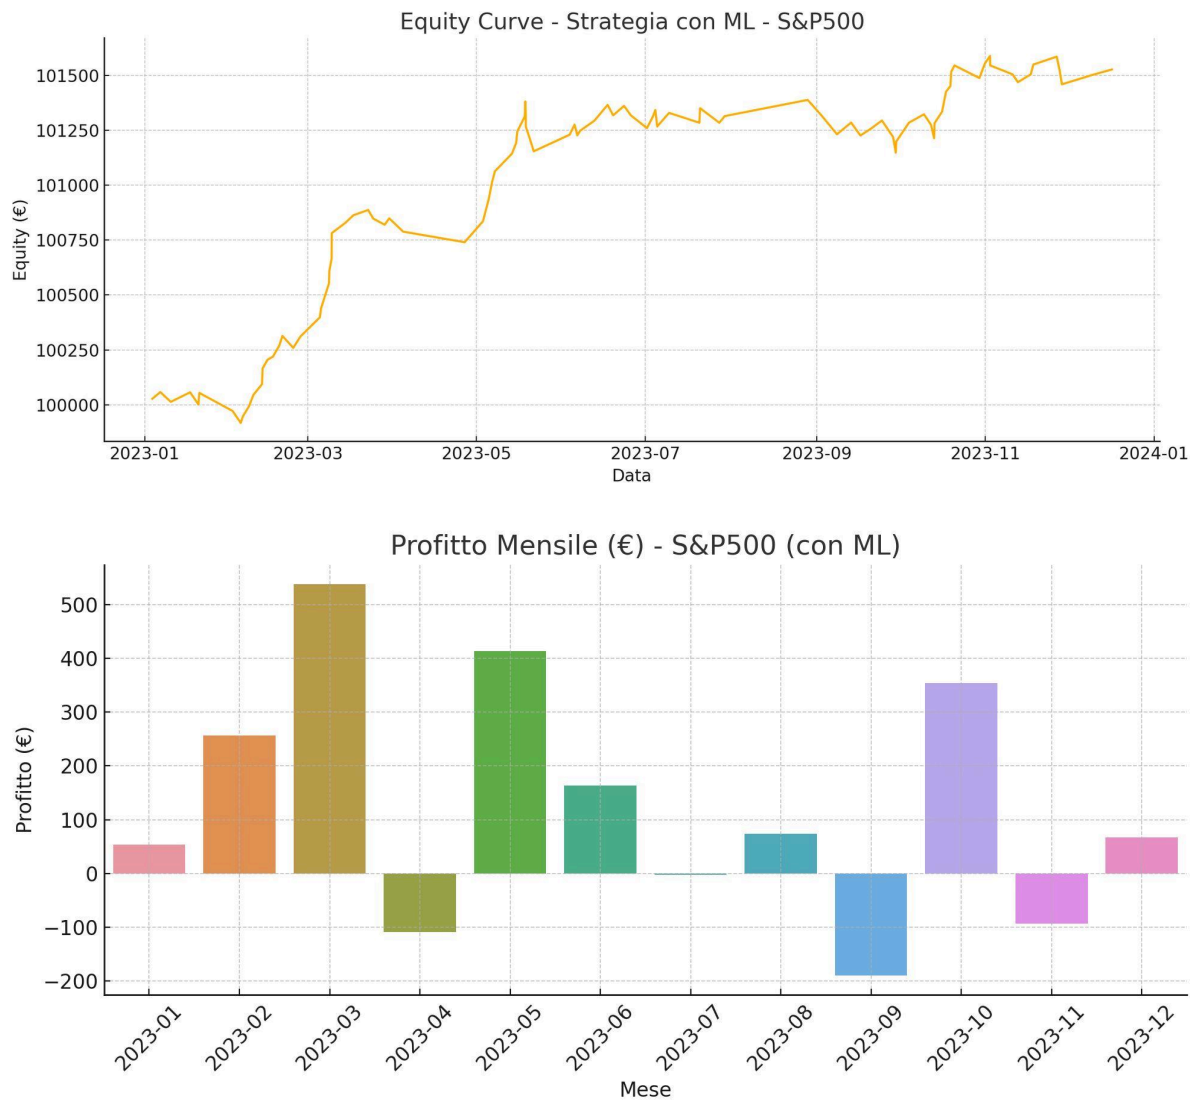
### 5.4. - S&P500 (0.05 lotti)

Nel caso dello S&P500, la strategia basata sull’uso del modello di Machine Learning ha mostrato una crescita complessiva dell’equity positiva ma meno marcata rispetto ad altri asset. La curva equity è caratterizzata da un incremento iniziale deciso, seguito da una fase di lateralità tra giugno e ottobre, per poi concludere l’anno con un lieve recupero. Il comportamento è stato generalmente più prudente, con fasi di consolidamento evidenti.

Analizzando la distribuzione dei profitti mensili, si osservano buoni risultati nei mesi di marzo, maggio e ottobre, ma anche perdite nei mesi di aprile, settembre e novembre. Questo denota una maggiore sensibilità del modello ML ai cambi di

regime di mercato, ma allo stesso tempo una gestione più attenta della volatilità. Al contrario, la strategia senza ML ha evidenziato una crescita dell’equity più costante e regolare. La curva mostra una progressione lineare, priva di ampie escursioni o drawdown rilevanti. Anche la distribuzione mensile dei profitti risulta essere più bilanciata: i guadagni sono distribuiti in modo uniforme, con solo due mesi negativi alla fine dell’anno (novembre e dicembre), che segnano una lieve fase di correzione.



Strategia con Machine Learning



Win Rate	65.98%
Max Drawdown	0.24%
Profitto Assoluto	1.526\$
Profitto Percentuale	1.53%



## Strategia senza Machine Learning



Win Rate	68.04%
Max Drawdown	0.28%
Profitto Assoluto	1.200\$
Profitto Percentuale	1.2%

## Conclusione per S&P500

In sintesi:

- Con ML: maggiore cautela e controllo, ma rendimento più contenuto e fasi di stagnazione.
- Senza ML: rendimento più fluido, ma con maggiore esposizione nelle fasi finali.

Nel complesso, entrambe le strategie si sono dimostrate valide, ma con profili di rischio/rendimento differenti. Il modello ML, anche in presenza di una performance comparabile, ha confermato la sua funzione di ottimizzazione del rischio.


### 5.5. - DAX40 (0.05 lotti)


Nel caso del DAX40, l'introduzione del modello di Machine Learning ha portato a un comportamento piuttosto interessante. Osservando la equity curve della strategia con ML, si nota un progresso inizialmente regolare e costante fino a metà anno, seguito da un leggero appiattimento nella seconda metà. Nonostante una breve fase negativa ad agosto, la strategia ha mantenuto un trend positivo, ma con minor accelerazione rispetto ai mesi precedenti.

I profitti mensili con ML mostrano una crescita molto solida tra aprile e giugno, con il picco massimo raggiunto a giugno, seguito però da una performance meno brillante nella seconda metà dell'anno, in particolare ad agosto e dicembre, mesi leggermente negativi.

Al contrario, la equity curve senza ML appare più stabile e lineare nel tempo, mantenendo una crescita più costante fino a fine anno. Questo comportamento trova conferma anche nei profitti mensili senza ML, che pur presentando un andamento meno esplosivo nella prima parte dell'anno, risultano molto regolari e costanti nel lungo periodo, con un picco evidente a luglio.


### Strategia con Machine Learning






Win Rate	63.16%
Max Drawdown	0.26%
Profitto Assoluto	2.073\$
Profitto Percentuale	2.07%

## Strategia senza Machine Learning





Win Rate	74.4%
Max Drawdown	0.16%
Profitto Assoluto	3.528\$
Profitto Percentuale	3.53%

### Conclusione DAX40

Nel complesso, la strategia con ML ha dimostrato maggiore capacità di generare profitti più elevati in singoli mesi, ma quella senza ML si è distinta per una crescita più regolare e continua nel tempo, risultando potenzialmente più adatta a contesti in cui la costanza di rendimento è una priorità.

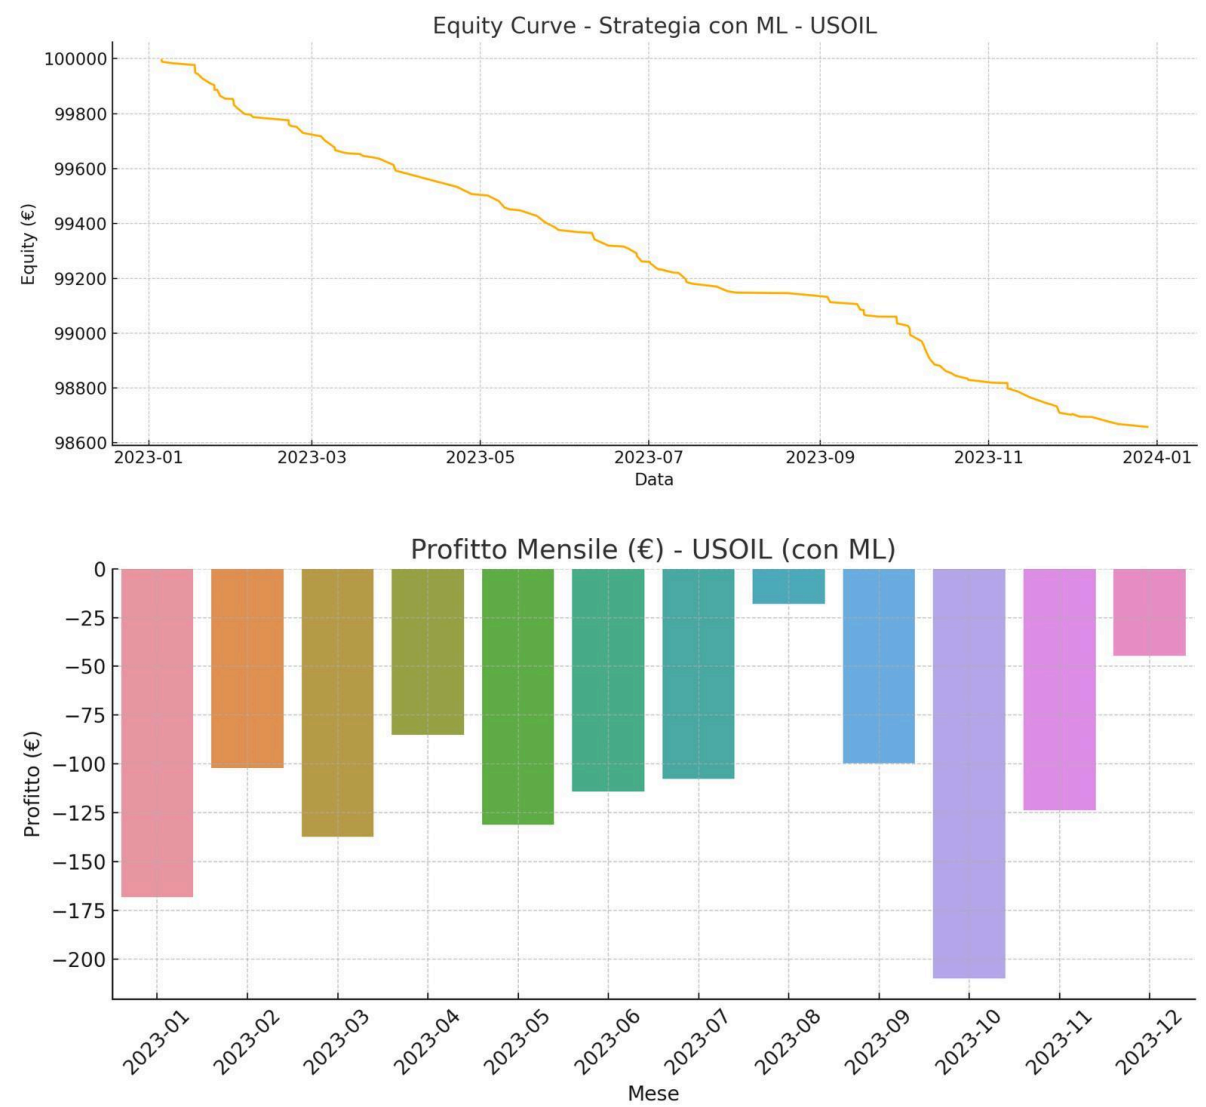
### 5.6. - USOIL (0.05 lotti)

Nel caso di USOIL, i risultati ottenuti con il modello basato su Machine Learning si sono rivelati nettamente negativi. La curva di equity presenta un trend costantemente decrescente lungo tutto l'arco dell'anno, con una perdita continua e priva di fasi di recupero significative. Anche l'analisi mensile conferma l'inefficienza della strategia: tutti i mesi hanno registrato chiusure in perdita, con picchi particolarmente negativi a gennaio (-168€), ottobre (-208€) e novembre (-126€). Il modello ML, in questo contesto, ha mostrato limiti evidenti nell'adattarsi alla natura irregolare e fortemente condizionata da eventi esogeni del mercato del petrolio.

Anche la versione della strategia senza l'integrazione del modello ML ha ottenuto un risultato negativo, sebbene leggermente più contenuto. La curva di equity è comunque decrescente, ma con una pendenza meno marcata rispetto alla controparte con ML. I profitti mensili confermano un comportamento simile: anche in questo



caso, tutte le chiusure sono state in rosso, con valori generalmente più moderati. Tuttavia, nessun mese ha mostrato un'inversione significativa del trend.

Strategia con Machine Learning



Win Rate	68.03%
Max Drawdown	1.34%
Profitto Assoluto	-1.342\$
Profitto Percentuale	-1.34%

Strategia senza Machine Learning



Win Rate	69.39%
Max Drawdown	1.03%
Profitto Assoluto	-1.026\$
Profitto Percentuale	-1.03%

### Conclusione USOIL

Nel complesso, entrambi i sistemi si sono dimostrati inefficaci su USOIL nel periodo analizzato. Il mercato petrolifero, caratterizzato da elevata volatilità, forte sensibilità a fattori geopolitici e dinamiche fondamentali complesse, sembra richiedere approcci differenti rispetto a quelli impiegati. In questa fase, l'esclusione dell'asset dal portafoglio operativo rappresenta una scelta coerente.

### 5.7. - BTC/USD (0.5 lotti)


La versione con ML presenta una crescita dell'equity costante e ben distribuita nel tempo. L'incremento risulta particolarmente marcato nei mesi di giugno e novembre, con una fase di consolidamento stabile tra luglio e ottobre. Il drawdown è contenuto e la curva mostra una buona linearità, suggerendo coerenza tra le decisioni del modello e l'andamento del mercato.

A livello mensile, il profitto è positivo in quasi tutti i periodi, con un picco significativo a giugno. La strategia si dimostra efficace nella gestione del trend e nella continuità della performance.


La versione senza ML mantiene una struttura di crescita regolare ma con performance inferiori. La fase iniziale dell'anno è positiva, seguita da un rallentamento nei mesi centrali. Le perdite di maggio, agosto e dicembre impattano negativamente sulla curva, riducendo il capitale complessivo accumulato rispetto alla versione con ML.

L'equity curve risulta meno inclinata e più soggetta a fluttuazioni, con un ritmo di accumulazione più lento e meno ottimizzato nei punti di espansione del mercato.

### Strategia con Machine Learning









Win Rate	73.5%
Max Drawdown	0.79%
Profitto Assoluto	10.754\$
Profitto Percentuale	10.75%

## Strategia senza Machine Learning







Win Rate	59.41%
Max Drawdown	0.60%
Profitto Assoluto	4.434\$
Profitto Percentuale	4.43%

### Conclusione BTC/USD

Su BTC/USD la strategia con Machine Learning ha nettamente sovraperformato quella classica, garantendo una crescita più marcata e una maggiore stabilità. L'algoritmo ML ha saputo intercettare con efficacia i periodi di espansione, soprattutto tra maggio e luglio, contenendo meglio le fasi correttive.


### 5.8. - EUR/USD (0.05 lotti)

Nel caso dell'EUR/USD, la strategia con Machine Learning mostra una crescita graduale dell'equity lungo tutto il 2023, con una performance più contenuta rispetto alla versione tradizionale ma comunque positiva. I guadagni si distribuiscono in modo equilibrato, con alcuni mesi di particolare forza (gennaio, febbraio, maggio e settembre), alternati a momenti di consolidamento e leggere correzioni, visibili anche nell'equity curve. Questo comportamento riflette una logica più selettiva e prudente del modello ML, che tende ad evitare condizioni di mercato meno favorevoli, limitando drawdown importanti ma anche picchi di profitto.

La strategia senza ML, invece, evidenzia una crescita più decisa e costante, con un equity line che si sviluppa in modo regolare e privo di oscillazioni significative. Il modello tecnico ha generato profitti sostenuti durante tutto l'anno, in particolare nei mesi di febbraio, settembre, ottobre e novembre. L'assenza di flessioni evidenti lungo



l'equity suggerisce una forte coerenza della logica operativa, che si adatta bene alle caratteristiche cicliche del cambio EUR/USD.

Strategia con Machine Learning



Win Rate	76.19%
Max Drawdown	0.21%
Profitto Assoluto	1.953\$
Profitto Percentuale	1.95%

## Strategia senza Machine Learning



Win Rate	84.09%
Max Drawdown	0.15%
Profitto Assoluto	4.068\$
Profitto Percentuale	4.07%

## Conclusione EUR/USD

Nel complesso, mentre il modello con ML si comporta in maniera più adattiva e conservativa, il modello tecnico tradizionale si è dimostrato più redditizio in questo specifico contesto valutario.


### **5.9. - USD/JPY (0.05 lotti)**

Nel confronto tra la strategia con e senza modello di Machine Learning (ML) su USD/JPY, emergono differenze significative a livello di rendimento, continuità e comportamento del capitale.

La strategia senza ML mostra una crescita dell'equity regolare e priva di correzioni sostanziali, con un rendimento costante nel corso dei mesi. I profitti mensili sono stabili e ben distribuiti, con picchi rilevanti a maggio e settembre e un andamento generalmente positivo. L'equity curve evidenzia una salita graduale e fluida, priva di fasi laterali o di drawdown marcati.



Al contrario, la strategia con ML presenta una prima metà dell'anno caratterizzata da lateralità e correzioni frequenti, con una fase di accumulo lenta e poco direzionale. A partire da ottobre, il modello mostra un'accelerazione significativa del rendimento, con un'equity curve in netta salita e un picco massimo a novembre. L'andamento mensile è più volatile rispetto alla versione senza ML: si osservano infatti perdite nei primi mesi, seguite da profitti crescenti e concentrati nella parte finale dell'anno. Questo comportamento suggerisce una fase di apprendimento o adattamento iniziale del modello, che culmina però in una forte esplosione dei profitti negli ultimi mesi.

Strategia con Machine Learning



Win Rate	67.57%
Max Drawdown	0.35%
Profitto Assoluto	1.148\$
Profitto Percentuale	1.15%

## Strategia senza Machine Learning



Win Rate	81.4%
Max Drawdown	0.23%
Profitto Assoluto	2.931\$
Profitto Percentuale	2.93%

## Conclusione USD/JPY

Nel complesso, il modello di ML mostra una maggiore reattività nella parte finale dell'anno, ma a discapito di una fase iniziale più turbolenta. La versione senza ML, invece, predilige stabilità e continuità fin dal principio, risultando più robusta ma meno dinamica nel lungo termine.


### 5.10. - AUD/USD (0.05 lotti)


La strategia basata su Machine Learning applicata ad AUD/USD ha mostrato un comportamento altalenante ma nel complesso positivo. L'equity curve evidenzia una crescita graduale, con fasi di consolidamento e qualche correzione intermedia. Nonostante alcune oscillazioni nella prima metà dell'anno, il modello ha mantenuto una direzione generale rialzista, chiudendo l'anno con un incremento dell'equity.

Dal punto di vista mensile, il 2023 si apre con un gennaio molto positivo (oltre 350€), seguito da un rallentamento tra febbraio e aprile. Marzo chiude infatti in negativo, ma nei mesi successivi si osserva una ripresa progressiva con performance costantemente sopra lo zero, ad eccezione di ottobre. Novembre rappresenta un altro mese forte per la strategia, contribuendo in modo significativo al risultato finale.

Confrontando questa performance con quella della strategia senza Machine Learning, notiamo che anche quest'ultima mostra un andamento positivo e costante. L'equity curve è più regolare, con un numero inferiore di correzioni evidenti. In termini di profitti mensili, però, la strategia tradizionale tende ad avere una distribuzione più stabile, con più mesi in verde e performance meno altalenanti. I mesi di febbraio, marzo, giugno, luglio e ottobre sono stati particolarmente favorevoli per il modello senza ML.


### Strategia con Machine Learning






Win Rate	72.73%
Max Drawdown	0.16%
Profitto Assoluto	875.94\$
Profitto Percentuale	0.88%

## Strategia senza Machine Learning







Win Rate	73.47%
Max Drawdown	0.30%
Profitto Assoluto	1.824\$
Profitto Percentuale	1.82%

### Conclusione AUD/USD

In sintesi, su AUD/USD il modello con Machine Learning ha prodotto risultati buoni, ma con maggiore variabilità rispetto alla strategia senza ML, che mostra una maggiore stabilità mensile. Entrambe le strategie hanno generato profitto, ma la versione ML ha avuto bisogno di più tempo per consolidare il proprio vantaggio.

## 6. Analisi comparativa con/senza ML

L'integrazione del Machine Learning nella strategia di trading ha prodotto risultati eterogenei a seconda del mercato di riferimento, evidenziando vantaggi significativi in alcuni casi e performance più deboli in altri, rispetto all'approccio tradizionale.

Nei mercati ad alta volatilità e direzionalità come DJ30, DAX40 e BTC/USD, il modello con ML ha mostrato un netto vantaggio. In particolare, su BTC/USD, l'equity curve evidenzia una crescita robusta e costante per tutto l'anno, con un rendimento decisamente superiore rispetto alla versione senza ML. Anche su DJ30 e DAX40, l'approccio con ML ha permesso di identificare e sfruttare meglio le fasi

impulsive del mercato, con equity curve più inclinate e profitti mensili generalmente più elevati.

Nel caso dell'S&P500, la differenza tra le due strategie è stata più contenuta ma comunque favorevole al modello con ML, che ha garantito una progressione più regolare e una migliore gestione delle fasi laterali. Anche su EUR/USD la strategia con ML si è comportata bene, con un'equity curve in crescita e una distribuzione dei profitti più diversificata, pur non superando in modo netto la versione senza ML, che si è distinta per continuità e stabilità mensile.

Nei mercati più complessi o rumorosi, come USOIL e AUD/USD, i risultati del modello con ML sono stati più contrastanti. Su USOIL, la strategia con ML ha mostrato un deterioramento dell'equity costante, peggiorando sensibilmente rispetto alla versione base. Questo suggerisce che il modello non è riuscito a interpretare correttamente i segnali del mercato o a filtrare il rumore presente su questo asset. Su AUD/USD, invece, la strategia ML ha ottenuto un rendimento positivo ma meno stabile rispetto alla versione senza ML, che ha mostrato una crescita più regolare e meno soggetta a drawdown.

Per quanto riguarda USD/JPY, l'approccio con ML ha chiuso in positivo, con un'accelerazione nella parte finale dell'anno. Tuttavia, la versione tradizionale si è comportata meglio nel complesso, mostrando una curva di equity più costante e profitti mensili più solidi, soprattutto nei mesi centrali dell'anno.

## **Conclusion**

L'uso del Machine Learning ha dimostrato di essere particolarmente efficace nei mercati con una componente direzionale marcata e nei contesti ad alta volatilità, dove l'analisi delle caratteristiche non lineari e dei pattern complessi può offrire un vantaggio informativo. Tuttavia, in mercati più stabili o rumorosi, dove l'effetto dei fattori stocastici prevale, la strategia tradizionale si è rivelata più affidabile e performante.

Questa analisi evidenzia la necessità di una selezione oculata degli asset su cui applicare modelli ML, e suggerisce la possibilità di integrare sistemi ibridi, in cui l'attivazione del modello avvenga solo in presenza di condizioni di mercato favorevoli alla sua natura predittiva.

## **7. Conclusion e Sviluppi futuri**

Il progetto ha dimostrato l'efficacia dell'integrazione di modelli di Machine Learning all'interno di una strategia di trading algoritmico basata su logiche istituzionali. L'obiettivo principale è stato quello di testare l'impatto reale dei modelli predittivi sul

rendimento di un Expert Advisor (EA), in un contesto multi-asset e multi-strategia, valutando attentamente i benefici e i limiti rispetto a una logica classica senza AI.

In particolare, sono stati utilizzati due modelli: una **Random Forest per la previsione dell'operazione** e un **modello di allocazione del rischio (AMM)** basato su regressione lineare e Random Forest. Entrambi sono stati sviluppati in C++, integrati via DLL in MT4, e addestrati su un **dataset strutturato contenente le seguenti feature**: EMA, ADX, POC, VAH, VAL, volume e ATR. Il dataset è stato creato internamente tramite la combinazione di indicatori proprietari e dati storici di mercato.

I risultati riportati in questo report sono **relativi a questi modelli addestrati su tale dataset**, e potrebbero variare nel caso di un nuovo addestramento o su altri campioni temporali.

La finalità del progetto è **rendere pubblica la struttura dei modelli e i risultati ottenuti**, promuovendo una logica trasparente e replicabile che possa servire da base per ulteriori sviluppi nell'ambito del trading algoritmico guidato dall'intelligenza artificiale.

Tutto il materiale utilizzato nel progetto, inclusi:

- **l'indicatore Volume Profile (POC, VAH, VAL),**
- **i modelli ML (previsione e allocazione rischio),**
- **i dataset utilizzati per l'addestramento.**

Sviluppato e pubblicato da

**[Marco Fedeli]**

*Trader quantitativo e progettista AI*